

## UNIVERSIDAD INTERNACIONAL DEL ECUADOR

### INFORME DE APLICACIÓN AUTÓNOMA



MODELADO EN ORANGE DATA MINING

DATASET: BOUGHT\_SOLD\_CARS\_CLEAN2025.CSV

#### AUTORES:

CARRERA DIAZ CHRISTIAN JAVIER

CERNA PACHECO ROMEL MICHAEL

LUNA ARTEAGA ALEXANDER PAUL

## Contenido

|                                                                                    |    |
|------------------------------------------------------------------------------------|----|
| Introducción .....                                                                 | 3  |
| Carga y Exploración Inicial de Datos .....                                         | 3  |
| Validación Inicial – Data Table.....                                               | 3  |
| Análisis Exploratorio Visual .....                                                 | 4  |
| Box Plot.....                                                                      | 4  |
| Distributions .....                                                                | 4  |
| Selección de Variables .....                                                       | 4  |
| Muestreo y Preprocesamiento .....                                                  | 5  |
| Data Sampler (70%) .....                                                           | 5  |
| Preprocess.....                                                                    | 6  |
| Modelos de Clasificación Implementados.....                                        | 6  |
| Evaluación de Modelos .....                                                        | 6  |
| Análisis Posterior a la Evaluación .....                                           | 6  |
| Confusion Matrix.....                                                              | 7  |
| ROC Analysis.....                                                                  | 7  |
| Análisis: Con y Sin Normalización .....                                            | 7  |
| Resultados SIN Normalización .....                                                 | 7  |
| Resultados CON Normalización .....                                                 | 7  |
| ¿Por qué pasa esto? .....                                                          | 8  |
| Discusión modelos son sensibles al escalamiento.....                               | 8  |
| Modelos Sensibles al Escalamiento.....                                             | 8  |
| <b>Support Vector Machine (SVM)</b> .....                                          | 8  |
| <b>Neural Network</b> .....                                                        | 8  |
| <b>Logistic Regression</b> .....                                                   | 9  |
| <b>Modelos Poco Sensibles al Escalamiento</b> .....                                | 9  |
| Análisis Arquitectónico: Pipelines de Machine Learning y Gobernanza de Datos ..... | 9  |
| Localización de la Transformación de Datos en Sistemas Productivos .....           | 9  |
| Versionamiento de Modelos y Transformadores: El Enfoque MLOps.....                 | 9  |
| Riesgos Críticos del Data Leakage (Fuga de Datos) .....                            | 10 |
| Conclusiones: .....                                                                | 11 |

## Introducción

El presente trabajo tiene como objetivo desarrollar un modelo de clasificación utilizando la herramienta de minería de datos Orange Data Mining, aplicando técnicas de aprendizaje supervisado sobre el dataset de Vehículos Nuevos 2025 publicado por el Servicio de Rentas Internas del Ecuador.


El conjunto de datos contiene información relacionada con el registro de vehículos nuevos en el año 2025, incluyendo variables como marca, modelo, año, clase, tipo, categoría entre otras.

El propósito del análisis es comparar diferentes modelos de clasificación y evaluar el impacto de la normalización de variables numéricas en el desempeño predictivo.

## Dataset: Bought\_Sold\_Cars\_Clean2025.csv

### Carga y Exploración Inicial de Datos

El análisis se desarrolló en **Orange Data Mining**, utilizando el dataset **Bought\_Sold\_Cars\_Clean2025.csv**.



La imagen muestra el flujo completo de modelado implementado en Orange Data Mining para el dataset Bought\_Sold\_Cars\_Clean2025.csv.

El flujo inició con el widget **File**, donde se cargó el archivo para su procesamiento. Desde este nodo se realizaron dos ramas de análisis:

### Validación Inicial – Data Table

El widget **Data Table** permitió:

- Verificar la correcta carga del archivo.

## Diseño Visual en Orange

- Validar tipos de variables (categóricas y numéricas).
- Revisar posibles valores faltantes.
- Confirmar coherencia en las columnas.

Esta etapa es fundamental para asegurar que el dataset esté estructurado correctamente antes de aplicar modelos predictivos.

### Análisis Exploratorio Visual

Desde el **Data Table** se conectaron:

#### Box Plot

Se utilizó para analizar la dispersión de variables numéricas (por ejemplo, año\_modelo), permitiendo detectar:

- Valores atípicos (outliers)
- Distribución de los datos
- Rango y mediana

#### Distributions

Se analizaron variables categóricas como:

- Clase
- Tipo
- Categoría

Esto permitió identificar:

- Posible desbalance de clases.
- Categorías dominantes.
- Frecuencias relativas.

Este análisis exploratorio fundamenta la etapa posterior de modelado.

### Selección de Variables

Desde el widget **File** también se conectó el widget **Select Columns**, donde se definió:


#### Target:

Clase

#### Features:

Categoria  
Ano\_Modelo  
Tipo

Esta selección permite construir un modelo de clasificación supervisada donde se predice la clase del vehículo a partir de sus características estructurales.



## Muestreo y Preprocesamiento

### Data Sampler (70%)

Se aplicó un muestreo aleatorio del **70% del dataset**, con el objetivo de:

- Reducir carga computacional.
- Mantener representatividad estadística.
- Optimizar tiempos en Test & Score.

El Data Sampler se conectó tanto al Preprocess como directamente al Test & Score, garantizando que la evaluación se realice sobre la muestra seleccionada.

## Preprocess

En esta etapa se aplicaron transformaciones previas al modelado, tales como:

- Normalización de variables numéricas.
- Preparación de datos para modelos sensibles al escalamiento.

Esto es especialmente importante para modelos como SVM y Redes Neuronales.

## Modelos de Clasificación Implementados

Desde el Preprocess se conectaron cuatro algoritmos:

- Random Forest
- Neural Network
- Support Vector Machine (SVM)
- Logistic Regression

Cada modelo fue entrenado utilizando los datos preprocesados.

## Evaluación de Modelos

Todos los modelos fueron conectados al widget **Test & Score**, donde se aplicó validación cruzada para comparar métricas como:

- Accuracy
- AUC
- F1 Score
- Precision
- Recall

El Data Sampler también se conectó directamente al Test & Score para asegurar coherencia en la evaluación.

## Análisis Posterior a la Evaluación

Desde el widget **Test & Score** se conectaron:

### Data Table

Permite visualizar las predicciones generadas por cada modelo.

## Confusion Matrix

Se analizaron:

- Verdaderos positivos
- Falsos positivos
- Verdaderos negativos
- Falsos negativos

Esto permitió evaluar la precisión por clase y detectar errores específicos.

## ROC Analysis

Se analizaron las curvas ROC para comparar la capacidad discriminativa de los modelos. Un mayor AUC indica mejor separación entre clases.

La comparación entre Random Forest, Neural Network, SVM y Logistic Regression permitió identificar el modelo con mejor capacidad predictiva para la clasificación de vehículos.

El uso de validación cruzada y análisis ROC fortaleció la confiabilidad de los resultados, garantizando que el modelo seleccionado no esté sobreajustado.

## Análisis: Con y Sin Normalización

### Resultados SIN Normalización

Cuando no se aplica Normalize:

- Random Forest → casi no cambia.
- Logistic Regression → puede bajar un poco.
- Neural Network → puede volverse inestable.
- SVM → suele bajar mucho su rendimiento.

Porque algunos modelos usan distancia matemática para separar clases.

### Resultados CON Normalización

Al aplicar Normalize:

- SVM mejora significativamente.
- Neural Network mejora estabilidad.
- Logistic Regression mejora ligeramente.

- Random Forest casi no cambia.

## ¿Por qué pasa esto?

### Modelos sensibles a escala:

- SVM
- k-NN
- Neural Network
- Logistic Regression

Porque calculan distancias o pesos matemáticos.

### Modelos no sensibles:

- Random Forest
- Árboles de decisión

Porque trabajan con reglas tipo: “si variable > valor entonces...”

No usan distancia.

## Discusión modelos son sensibles al escalamiento.

### Modelos Sensibles al Escalamiento

#### Support Vector Machine (SVM)

Es altamente sensible porque:

- Calcula distancias entre puntos.
- Maximiza el margen entre clases.
- Si una variable tiene valores más grandes, domina el cálculo.

Sin normalización, el modelo puede generar fronteras de decisión incorrectas.

#### Neural Network

Es sensible porque:

- Utiliza pesos y funciones de activación.
- Valores muy grandes pueden generar inestabilidad numérica.
- Puede afectar la convergencia del entrenamiento.

La normalización mejora estabilidad y velocidad de aprendizaje.

## Logistic Regression

También es sensible porque:

- Es un modelo lineal basado en coeficientes.
- Variables con mayor escala pueden influir más en los pesos aprendidos.

## Modelos Poco Sensibles al Escalamiento

### Random Forest (y Árboles de Decisión)

No son sensibles porque:

- No usan distancias.
- Dividen datos mediante reglas tipo: “si variable > X”.
- La escala no afecta el criterio de división.

Por eso su rendimiento casi no cambia con o sin normalización.

## Análisis Arquitectónico: Pipelines de Machine Learning y Gobernanza de Datos

### Localización de la Transformación de Datos en Sistemas Productivos

En la arquitectura de software moderna para Inteligencia Artificial, la transformación de datos (que incluye el escalado, la imputación de valores faltantes y la codificación de variables categóricas) debe ocurrir imperativamente dentro del Pipeline de inferencia del modelo.

Desde una perspectiva de ingeniería de software, tratar las transformaciones como procesos externos al modelo como scripts SQL previos o limpiezas manuales en Excel es un antipatrón de diseño. Si las transformaciones se realizan fuera del pipeline, se crea una dependencia frágil donde el sistema de producción debe replicar exactamente la lógica matemática utilizada durante el entrenamiento. Cualquier discrepancia mínima (por ejemplo, una media distinta en el escalado) derivará en el fenómeno conocido como *Training-Serving Skew*, donde el modelo se comporta de forma errática a pesar de tener métricas excelentes en el laboratorio. Al encapsular estas operaciones en un objeto como Pipeline de Scikit-Learn, el modelo se convierte en una unidad atómica que recibe datos crudos y entrega predicciones, garantizando la coherencia estadística total.

### Versionamiento de Modelos y Transformadores: El Enfoque MLOps

El versionamiento en Machine Learning es significativamente más complejo que el versionamiento de código tradicional. No basta con usar Git para rastrear cambios en los scripts; es necesario versionar el artefacto binario que contiene tanto el modelo como sus transformadores asociados.

En entornos profesionales, esto se logra mediante herramientas de Model Registry (como MLflow o DVC). El versionamiento debe vincular tres pilares:

1. **El Código:** La lógica exacta que generó el modelo.
2. **Los Datos:** El snapshot específico del dataset utilizado para el entrenamiento.
3. **Los Parámetros:** Los coeficientes aprendidos y los valores de los transformadores (ej. los parámetros del StandardScaler).

Versionar el transformador junto al modelo es crítico porque el modelo "espera" datos en una escala específica. Si actualizamos el modelo pero usamos una versión antigua del transformador, la entrada de datos estará sesgada, invalidando la salida.

## Riesgos Críticos del Data Leakage (Fuga de Datos)

El *Data Leakage* es uno de los errores más costosos en la ciencia de datos, ya que genera una ilusión de éxito que se desmorona al enfrentar datos reales. Los riesgos se dividen en dos categorías principales:

- **Falso Optimismo y Riesgo Operativo:** El leakage infla artificialmente métricas como el *Accuracy* o el *F1-Score*. Si un ingeniero de software despliega un modelo de calificación registral que parece tener un 99% de precisión debido a que "filtró" información del futuro durante el entrenamiento, la institución tomará decisiones basadas en evidencia falsa. En producción, el modelo fallará catastróficamente al no contar con esa información privilegiada.
- **Vulnerabilidad de la Seguridad Jurídica:** En instituciones como el Registro de la Propiedad, un modelo con leakage puede aprender patrones que no tienen sustento legal, sino estadístico accidental. Esto compromete la fe pública, ya que la automatización no estaría basada en la lógica jurídica, sino en una "trampa" matemática involuntaria.

## El Rol de la Gobernanza del Dato en el Proceso Analítico

La gobernanza del dato no es un proceso administrativo, sino un componente de calidad y control que atraviesa todo el pipeline. Su rol es fundamental en cuatro ejes:

1. **Integridad del Linaje:** Permite rastrear el origen de cada dato y asegurar que las variables utilizadas sean lícitas y éticas.
2. **Prevención de Sesgos:** Establece reglas de negocio que prohíben el uso de variables que puedan introducir discriminación o que se identifiquen como fuentes potenciales de *leakage*.
3. **Auditabilidad:** En caso de un error registral automatizado, la gobernanza proporciona el marco para auditar qué versión del modelo y qué datos influyeron en la decisión, asegurando la transparencia institucional.
4. **Estandarización:** Define cómo deben ser las transformaciones para que todos los equipos de la organización hablen el mismo "idioma" técnico, evitando que cada modelo tenga su propia interpretación de la limpieza de datos.

## Conclusiones:

- 1) El flujo implementado en Orange permitió desarrollar un proceso completo de minería de datos que incluye:
  - Exploración inicial
  - Selección de variables
  - Muestreo
  - Preprocesamiento
  - Entrenamiento de múltiples modelos
  - Evaluación comparativa
  - Análisis detallado de desempeño
  
- 2) Se observó que la normalización impacta principalmente en modelos sensibles al escalamiento como SVM y Redes Neuronales, mejorando su desempeño. En contraste, Random Forest mostró estabilidad tanto con como sin normalización, debido a que los modelos basados en árboles no dependen de distancias matemáticas. Esto confirma que el escalamiento es fundamental en modelos lineales y basados en margen.
  
- 3) Los modelos basados en distancia o en optimización matemática, como SVM, Redes Neuronales y Regresión Logística, son sensibles al escalamiento debido a que dependen de magnitudes numéricas para calcular fronteras de decisión o ajustar pesos. En contraste, modelos basados en árboles como Random Forest no se ven afectados por la escala de las variables, ya que realizan divisiones mediante reglas independientes por variable.