


UNIVERSIDAD INTERNACIONAL DEL ECUADOR

INFORME DE APLICACIÓN AUTÓNOMA



MODELADO EN ORANGE DATA MINING

DATASET: BOUGHT_SOLD_CARS_CLEAN2025.CSV

AUTORES:

- CARRERA DIAZ CHRISTIAN JAVIER
- CERNA PACHECO ROMEL MICHAEL
- LUNA ARTEAGA ALEXANDER PAUL

Contenido

Introducción	3
Carga y Exploración Inicial de Datos.....	3
Validación Inicial – Data Table	5
Análisis Exploratorio Visual	6
Box Plot	6
Distributions	7
Selección de Variables	8
Muestreo y Preprocesamiento	9
Data Sampler (70%)	9
Preprocess	10
Modelos de Clasificación Implementados	11
Evaluación de Modelos	12
Resultados por Modelo.....	12
Análisis Posterior a la Evaluación	13
Confusion Matrix.....	14
ROC Analysis.....	18
Análisis: Con y Sin Normalización.....	20
Resultados SIN Normalización	20
Resultados CON Normalización	21
¿Por qué pasa esto?	21
Discusión modelos son sensibles al escalamiento.....	21
Modelos Sensibles al Escalamiento.....	21
Support Vector Machine (SVM).....	21
Neural Network.....	22
Logistic Regression	22
Modelos Poco Sensibles al Escalamiento.....	22
Análisis Arquitectónico: Pipelines de Machine Learning y Gobernanza de Datos	23

Localización de la Transformación de Datos en Sistemas Productivos	23
Versionamiento de Modelos y Transformadores: El Enfoque MLOps.....	23
Riesgos Críticos del Data Leakage (Fuga de Datos).....	24
El Rol de la Gobernanza del Dato en el Proceso Analítico.....	24
Conclusiones:	25

Introducción

El presente trabajo tiene como objetivo desarrollar un modelo de clasificación utilizando la herramienta de minería de datos Orange Data Mining, aplicando técnicas de aprendizaje supervisado sobre el dataset de Vehículos Nuevos 2025 publicado por el Servicio de Rentas Internas del Ecuador.


El conjunto de datos contiene información relacionada con el registro de vehículos nuevos en el año 2025, incluyendo variables como marca, modelo, año, clase, tipo, categoría entre otras.

El propósito del análisis es comparar diferentes modelos de clasificación y evaluar el impacto de la normalización de variables numéricas en el desempeño predictivo.

Dataset: Bought_Sold_Cars_Clean2025.csv


Carga y Exploración Inicial de Datos

El análisis se desarrolló en **Orange Data Mining**, utilizando el dataset **Bought_Sold_Cars_Clean2025.csv**.



La imagen muestra el flujo completo de modelado implementado en Orange Data Mining para el dataset Bought_Sold_Cars_Clean2025.csv.

El flujo inició con el widget **File**, donde se cargó el archivo para su procesamiento.




Desde este nodo se realizaron dos ramas de análisis:

Validación Inicial – Data Table

El widget **Data Table** permitió:

- Verificar la correcta carga del archivo.
- Validar tipos de variables (categóricas y numéricas).
- Revisar posibles valores faltantes.
- Confirmar coherencia en las columnas.

Esta etapa es fundamental para asegurar que el dataset esté estructurado correctamente antes de aplicar modelos predictivos.



Data Table - Orange

File Edit View Window Help

Info

436602 instances
16 features (0.3 % missing data)
Target with 10 values
4 meta attributes (0.2 % missing data)

Variables

☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection

Clear Selection

☐ Select full rows

Restore Original Order

☒ Send Automatically

	clase	marca	modelo	canton	provincia
1	OMNIBUS	SCANIA	K410 CB AC 12....	QUITO	QUITO
2	OMNIBUS	MERCEDES BENZ	OF 1723 6.4 3P ...	QUITO	QUITO
3	CAMIONETA	FORD	F-150 XL AC 5.0...	QUITO	QUITO
4	CAMION	VOLKSWAGEN	DELIVERY 11.17...	QUITO	QUITO
5	MOTOCICLETA	RANGER	125FY	PASAJE	PASAJE
6	MOTOCICLETA	RANGER	125FY	EL EMPALME	EL EMPALME
7	MOTOCICLETA	RANGER	125FY	EL EMPALME	EL EMPALME
8	CAMION	MERCEDES BENZ	AROCS 3340 A...	AMBATO	AMBATO
9	CAMION	MERCEDES BENZ	AROCS 3340 A...	LATACUNGA	LATACUNGA
10	AUTOMOVIL	TOYOTA	RAV4 XLE CVT ...	MANTA	MANTA
11	MOTOCICLETA	RANGER	FE250-10A	AMBATO	AMBATO
12	MOTOCICLETA	RANGER	FE250-10A	AMBATO	AMBATO
13	MOTOCICLETA	RANGER	FE250-10A	GIRON	GIRON
14	MOTOCICLETA	RANGER	FE250-10A	SAN VICENTE	SAN VICENTE
15	CAMION	JAC	HFC1063KNR 4....	GENERAL ANT...	GENERAL ANT..
16	CAMION	JAC	HFC1063KNR 4....	SAN MIGUEL D...	SAN MIGUEL D
17	CAMION	FOTON	AUMARK E BJ1...	PUERTO QUITO	PUERTO QUITO
18	AUTOMOVIL	GAC	AION UT AC 5P...	CUENCA	CUENCA
19	AUTOMOVIL	GAC	AION UT AC 5P...	QUITO	QUITO
20	AUTOMOVIL	GAC	AION UT AC 5P...	DAULE	DAULE


Análisis Exploratorio Visual

Desde el **Data Table** se conectaron:

Box Plot

Se utilizó para analizar la dispersión de variables numéricas (por ejemplo, año_modelo), permitiendo detectar:

- Valores atípicos (outliers)
- Distribución de los datos
- Rango y mediana



La imagen muestra la cantidad de registros por tipo de vehículo.

Se observa un gran desbalance en los datos:

MOTOCICLETA → 288.049 (muy superior)

JEEP → 72.070

CAMIONETA → 32.130

AUTOMÓVIL → 26.511

CAMIÓN → 10.720

Las demás clases tienen menos de 2.000 registros.

Distributions

Se analizaron variables categóricas como:


- Clase
- Tipo
- Categoría

Esto permitió identificar:

- Posible desbalance de clases.

- Categorías dominantes.
- Frecuencias relativas.

Este análisis exploratorio fundamenta la etapa posterior de modelado.



Se observa claramente que:

MOTOCICLETA tiene la mayor frecuencia (muy superior al resto).

JEEP es la segunda clase más frecuente.

CAMIONETA y AUTOMÓVIL tienen valores medios.

Las demás clases (OMNIBUS, TANQUERO, TRAILER, VOLQUETA, ESPECIAL) tienen muy pocos registros.


Selección de Variables

Desde el widget **File** también se conectó el widget **Select Columns**, donde se definió:

Target: Clase

Features: Categoría, Ano_Modelo, Tipo

Esta selección permite construir un modelo de clasificación supervisada donde se predice la clase del vehículo a partir de sus características estructurales.




Muestreo y Preprocesamiento

Data Sampler (70%)

Se aplicó un muestreo aleatorio del **70% del dataset**, con el objetivo de:

- Reducir carga computacional.
- Mantener representatividad estadística.
- Optimizar tiempos en Test & Score.

El Data Sampler se conectó tanto al Preprocess como directamente al Test & Score, garantizando que la evaluación se realice sobre la muestra seleccionada.




Preprocess

En esta etapa se aplicaron transformaciones previas al modelado, tales como:

- Normalización de variables numéricas.
- Preparación de datos para modelos sensibles al escalamiento.

Esto es especialmente importante para modelos como SVM y Redes Neuronales.




Modelos de Clasificación Implementados

Desde el Preprocess se conectaron cuatro algoritmos:

- Random Forest
- Neural Network
- Support Vector Machine (SVM)
- Logistic Regression

Cada modelo fue entrenado utilizando los datos preprocesados.




Evaluación de Modelos

Todos los modelos fueron conectados al widget **Test & Score**, donde se aplicó validación cruzada para comparar métricas como:

- Accuracy, AUC, F1 Score, Precision, Recall

El Data Sampler también se conectó directamente al Test & Score para asegurar coherencia en la evaluación.



Test and Score - Orange

File Edit View Window Help

Cross validation

Number of folds: 10

☒ Stratified

☐ Cross validation by feature

Random sampling

Repeat train/test: 10

Training set size: 70 %

☐ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.993	0.939	0.938	0.938	0.939	0.883
Neural Network	0.764	0.705	0.608	0.653	0.705	0.328
SVM	0.562	0.339	0.395	0.522	0.339	0.052
Logistic Regression	0.661	0.684	0.556	0.470	0.684	0.246

Compare models by: Area under ROC curve

☐ Negligible diff.: 0.1

	Random Forest	Neural Network	SVM	Logistic Regression
Random Forest		1.000	1.000	1.000
Neural Network	0.000		1.000	1.000
SVM	0.000	0.000		0.000
Logistic Regression	0.000	0.000	1.000	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Resultados por Modelo

Random Forest

AUC: 0.993

Accuracy (CA): 0.939

F1: 0.938

Precision: 0.938

Recall: 0.939

MCC: 0.883

Interpretación:

- Desempeño sobresaliente.
- Alto equilibrio entre precisión y recall.
- Excelente capacidad discriminativa.
- Modelo claramente superior.

Neural Network

AUC: 0.764

Accuracy: 0.705

F1: 0.608

MCC: 0.328

Interpretación:

- Rendimiento moderado.
- Capta relaciones no lineales, pero no alcanza al Random Forest.
- MCC bajo indica menor consistencia en clasificación.

Logistic Regression

AUC: 0.661

Accuracy: 0.684

F1: 0.556

MCC: 0.246

Interpretación:

- Modelo lineal.
- Desempeño aceptable pero limitado.
- Probablemente los datos no son linealmente separables.

SVM

AUC: 0.562

Accuracy: 0.339

F1: 0.395

MCC: 0.052

Interpretación:

- Desempeño muy bajo.
- Prácticamente cercano al azar.
- Puede requerir ajuste de kernel o hiperparámetros.

Análisis Posterior a la Evaluación

Desde el widget **Test & Score** se conectaron:

Data Table

Permite visualizar las predicciones generadas por cada modelo.

Data Table (1) - Orange

Info
305622 instances
3 features
Target with 10 values
49 meta attributes (0.0 % missing data)

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
Clear Selection
☐ Select full rows

Restore Original Order
☒ Send Automatically


	clase	marca	modelo	canton	provincia	Random For
67	MOTOCICLETA	BAJAJ	PULSAR NS 160	VENTANAS	VENTANAS	MOTOCICLETA
68	MOTOCICLETA	DAYTONA	DY200 WING E...	GUAYAQUIL	GUAYAQUIL	MOTOCICLETA
69	MOTOCICLETA	LONCIN	JL200-68C	AMBATO	AMBATO	MOTOCICLETA
70	MOTOCICLETA	GALARDI	FORZA GL250FR	QUITO	QUITO	MOTOCICLETA
71	MOTOCICLETA	LONCIN	JL200-68C	QUITO	QUITO	MOTOCICLETA
72	MOTOCICLETA	LONCIN	JL200-68C	GENERAL ANT...	GENERAL ANT...	MOTOCICLETA
73	MOTOCICLETA	HONDA	DIO	GUAYAQUIL	GUAYAQUIL	MOTOCICLETA
74	MOTOCICLETA	SHINERAY	GN-X	GUAYAQUIL	GUAYAQUIL	MOTOCICLETA
75	MOTOCICLETA	LONCIN	LX150-69A	GUAYAQUIL	GUAYAQUIL	MOTOCICLETA
76	MOTOCICLETA	SHINERAY	XY150-15	GUAYAQUIL	GUAYAQUIL	MOTOCICLETA
77	JEEP	BYD	YUAN PRO GS ...	GUAYAQUIL	GUAYAQUIL	JEEP
78	MOTOCICLETA	TUKO	TK-H1	QUITO	QUITO	MOTOCICLETA
79	JEEP	MG	MG ZS AC 1.5 5...	GENERAL ANT...	GENERAL ANT...	JEEP
80	MOTOCICLETA	SHM	CHIEF 2.5	CAYAMBE	CAYAMBE	MOTOCICLETA
81	MOTOCICLETA	HAOJUE	NK150	MACHALA	MACHALA	JEEP
82	MOTOCICLETA	ZONSEN	ZS200GY-9	SALCEDO	SALCEDO	JEEP
83	MOTOCICLETA	YAMAHA	XTZ125E	GENERAL ANT...	GENERAL ANT...	MOTOCICLETA
84	MOTOCICLETA	DAYTONA	DY200 PREDAT...	GUAYAQUIL	GUAYAQUIL	MOTOCICLETA
85	JEEP	CHEVROLET	GROOVE LTZ A...	GUAYAQUIL	GUAYAQUIL	JEEP
86	CAMIONETA	GREAT WALL	POER AC 2.0 C...	GUAYAQUIL	GUAYAQUIL	CAMIONETA
87	MOTOCICLETA	SHINERAY	CLASICA	GENERAL ANT...	GENERAL ANT...	MOTOCICLETA
88	MOTOCICLETA	DAYTONA	DY 150 SPITFIRE	MACHALA	MACHALA	MOTOCICLETA
89	MOTOCICLETA	TUKO	TRICKSTER	PORTOVIEJO	PORTOVIEJO	MOTOCICLETA
90	MOTOCICLETA	DAYTONA	DY200 CRUCERO	GENERAL ANT...	GENERAL ANT...	MOTOCICLETA
91	JEEP	GEELY	AZKARRA I AC ...	QUITO	QUITO	JEEP
92	CAMION	SINOTRUK	CN HOWO NLS...	GENERAL ANT...	GENERAL ANT...	CAMION
93	MOTOCICLETA	THUNDER	MAMUT M2	JARAMIJO	JARAMIJO	MOTOCICLETA
94	MOTOCICLETA	SHINERAY	XY125-30A	BUENA FE	BUENA FE	MOTOCICLETA

Confusion Matrix

Se analizaron:

- Verdaderos positivos
- Falsos positivos
- Verdaderos negativos
- Falsos negativos

Esto permitió evaluar la precisión por clase y detectar errores específicos.



Se observa una fuerte concentración de valores en la diagonal principal, lo que indica:

- Alta cantidad de clasificaciones correctas
- Buen nivel de precisión global
- Bajo error relativo en la mayoría de clases

Esto confirma el alto Accuracy ($\approx 93.9\%$) observado en Test & Score.

Clases con Mejor Desempeño

Las siguientes categorías presentan muy buena clasificación (valores altos en diagonal y pocos errores):

CAMION (7111 correctos)

MOTOCICLETA (197447 correctos)

CAMIONETA (18403 correctos)

JEPP (44817 correctos)

Especialmente Motocicleta y Jeep, que muestran una clasificación muy sólida.

Principales Confusiones

Las mayores confusiones se observan entre:

Automóvil ↔ Jeep

Algunos Automóvil se clasifican como Jeep (1551)

Algunos Jeep se clasifican como Automóvil (792)

Diseño Visual en Orange

Esto indica similitud estructural entre ambas clases.

Camioneta ↔ Motocicleta

2878 Camioneta clasificadas como Motocicleta

1195 Motocicleta clasificadas como Camioneta

Posible desbalance o similitud en características seleccionadas.

Jeep ↔ Motocicleta

4141 Jeep clasificadas como Motocicleta

2438 Motocicleta clasificadas como Jeep

Esto sugiere que las variables actuales no separan completamente estas categorías.

Clases Minoritarias

Categorías como:

TANQUERO

TRAILER

VOLQUETA

OMNIBUS

Tienen menos registros totales, lo que puede afectar su estabilidad predictiva.

Sin embargo, el modelo mantiene una clasificación razonable en ellas.

Confusion Matrix - Orange

Clicking on cells or in headers outputs the corresponding data instances

Output: ☒ Predictions ☐ Probabilities

Show: Number of instances

	Predicted										Σ
	AUTOMOVIL	CAMION	CAMIONETA	ESPECIAL	JEEP	MOTOCICLETA	OMNIBUS	TANQUERO	TRAILER	VOLQUETA	
AUTOMOVIL	2729	0	2	1	823	15003	0	0	0	0	18558
CAMION	0	7182	0	185	0	0	49	0	25	63	7504
CAMIONETA	175	0	2	0	351	21963	0	0	0	0	22491
ESPECIAL	2	550	0	712	0	9	7	0	2	24	1306
JEEP	1533	0	8	0	4074	44834	0	0	0	0	50449
MOTOCICLETA	657	0	3	0	483	200492	0	0	0	0	201635
OMNIBUS	1	839	0	24	0	34	58	0	0	2	958
TANQUERO	0	382	0	6	0	0	5	0	1	0	394
TRAILER	0	929	0	45	0	0	30	0	29	68	1101
VOLQUETA	0	967	0	22	0	0	11	0	1	225	1226
Σ	5097	10849	15	995	5731	282335	160	0	58	382	305622

la imagen anterior muestra la **matriz de confusión** del modelo (Neural Network seleccionado) para clasificar tipos de vehículos. Se observa que la clase **MOTOCICLETA** es la

mejor predicha, con **200.492 aciertos**, lo que indica alta precisión en esa categoría. Sin embargo, existen confusiones importantes en otras clases, por ejemplo **AUTOMÓVIL**, **CAMIONETA** y especialmente **JEEP**, que en muchos casos se clasifican erróneamente como motocicleta (por ejemplo 44.834 Jeep fueron predichos como motocicleta). Esto sugiere que el modelo tiende a sobrepredecir la clase motocicleta, posiblemente por desbalance en los datos (es la clase con mayor número de registros). En general, el modelo funciona muy bien para la clase dominante, pero presenta errores considerables en clases similares, lo que afecta su desempeño global.

Confusion Matrix - Orange

Clicking on cells or in headers outputs the corresponding data instances

Show: Number of instances

	Predicted	AUTOMOVIL	CAMION	CAMIONETA	ESPECIAL	JEEP	MOTOCICLETA	OMNIBUS	TANQUERO	TRAILER	VOLQUETA	Σ
Actual	AUTOMOVIL	7932	0	2392	2	1725	6507	0	0	0	0	18558
	CAMION	0	1305	0	994	0	0	1658	883	1087	1577	7504
	CAMIONETA	8877	0	2565	0	1787	9262	0	0	0	0	22491
	ESPECIAL	2	404	3	61	6	2	584	11	76	157	1306
	JEEP	19683	0	6122	0	5131	19513	0	0	0	0	50449
	MOTOCICLETA	69817	0	25339	0	20362	86117	0	0	0	0	201635
	OMNIBUS	10	114	16	62	8	9	238	26	194	281	958
	TANQUERO	0	71	1	59	0	0	76	26	61	100	394
	TRAILER	0	255	0	133	0	0	247	165	146	155	1101
	VOLQUETA	0	168	0	164	0	0	319	188	186	201	1226
	Σ	106321	2317	36438	1475	29019	121410	3122	1299	1750	2471	305622

Confusion Matrix - Orange

Clicking on cells or in headers outputs the corresponding data instances

Show: Number of instances

	Predicted	AUTOMOVIL	CAMION	CAMIONETA	ESPECIAL	JEEP	MOTOCICLETA	OMNIBUS	TANQUERO	TRAILER	VOLQUETA	Σ
Actual	AUTOMOVIL	0	0	0	0	0	18558	0	0	0	0	18558
	CAMION	0	7303	0	197	0	0	4	0	0	0	7504
	CAMIONETA	0	0	0	0	0	22491	0	0	0	0	22491
	ESPECIAL	0	1237	0	54	0	11	4	0	0	0	1306
	JEEP	0	0	0	0	0	50449	0	0	0	0	50449
	MOTOCICLETA	0	0	0	0	0	201635	0	0	0	0	201635
	OMNIBUS	0	888	0	30	0	34	6	0	0	0	958
	TANQUERO	0	382	0	11	0	0	1	0	0	0	394
	TRAILER	0	991	0	110	0	0	0	0	0	0	1101
	VOLQUETA	0	1186	0	39	0	0	1	0	0	0	1226
	Σ	0	11987	0	441	0	293178	16	0	0	0	305622

La clase **MOTOCICLETA** tiene muchos aciertos (86.117), pero también muchísimos errores:

- 69.817 motocicletas fueron clasificadas como AUTOMÓVIL.
- 25.339 como CAMIONETA.

JEEP también presenta fuerte confusión con AUTOMÓVIL y MOTOCICLETA.

CAMIONETA y **AUTOMÓVIL** se confunden bastante entre sí.


Las clases pequeñas (OMNIBUS, TANQUERO, TRAILER, VOLQUETA, ESPECIAL) tienen bajo nivel de aciertos.

ROC Analysis


Se analizaron las curvas ROC para comparar la capacidad discriminativa de los modelos. Un mayor AUC indica mejor separación entre clases.

La comparación entre Random Forest, Neural Network, SVM y Logistic Regression permitió identificar el modelo con mejor capacidad predictiva para la clasificación de vehículos.

El uso de validación cruzada y análisis ROC fortaleció la confiabilidad de los resultados, garantizando que el modelo seleccionado no esté sobreajustado.




El modelo Random Forest presenta el mejor desempeño en términos de discriminación, evidenciado por su curva ROC cercana al vértice superior izquierdo y un AUC cercano a 1. En contraste, SVM muestra un desempeño cercano al clasificador aleatorio, indicando menor capacidad predictiva para la clase motocicleta.



ROC – Clase AUTOMÓVIL

- **Random Forest** → Casi perfecto (curva pegada arriba a la izquierda).
- **Neural Network** → Buen rendimiento.
- **Logistic Regression** → Regular.
- **SVM** → Bajo desempeño (cerca de la diagonal).

Para predecir AUTOMÓVIL, el mejor modelo es Random Forest. SVM es el más débil.



ROC – Clase CAMIONETA

- **Random Forest** → Nuevamente el mejor (AUC muy alto).
- **Neural Network** → Buen desempeño.
- **Logistic Regression** → Aceptable.
- **SVM** → El más bajo.

Análisis: Con y Sin Normalización

Resultados SIN Normalización

Cuando no se aplica Normalize:

- Random Forest → casi no cambia.
- Logistic Regression → puede bajar un poco.
- Neural Network → puede volverse inestable.
- SVM → suele bajar mucho su rendimiento.

Porque algunos modelos usan distancia matemática para separar clases.

Resultados CON Normalización

Al aplicar Normalize:

- SVM mejora significativamente.
- Neural Network mejora estabilidad.
- Logistic Regression mejora ligeramente.
- Random Forest casi no cambia.

¿Por qué pasa esto?

Modelos sensibles a escala:

- SVM
- k-NN
- Neural Network
- Logistic Regression

Porque calculan distancias o pesos matemáticos.

Modelos no sensibles:

- Random Forest
- Árboles de decisión

Porque trabajan con reglas tipo:
“si variable > valor entonces...”

No usan distancia.

Discusión modelos son sensibles al escalamiento.

Modelos Sensibles al Escalamiento

Support Vector Machine (SVM)

Es altamente sensible porque:

- Calcula distancias entre puntos.
- Maximiza el margen entre clases.

- Si una variable tiene valores más grandes, domina el cálculo.

Sin normalización, el modelo puede generar fronteras de decisión incorrectas.

Neural Network

Es sensible porque:

- Utiliza pesos y funciones de activación.
- Valores muy grandes pueden generar inestabilidad numérica.
- Puede afectar la convergencia del entrenamiento.

La normalización mejora estabilidad y velocidad de aprendizaje.

Logistic Regression

También es sensible porque:

- Es un modelo lineal basado en coeficientes.
- Variables con mayor escala pueden influir más en los pesos aprendidos.

Modelos Poco Sensibles al Escalamiento

Random Forest (y Árboles de Decisión)

No son sensibles porque:

- No usan distancias.
- Dividen los datos mediante reglas tipo: "si variable > X".
- La escala no afecta el criterio de división.

Por eso su rendimiento casi no cambia con o sin normalización.

Análisis Arquitectónico: Pipelines de Machine Learning y Gobernanza de Datos

Localización de la Transformación de Datos en Sistemas Productivos

En la arquitectura de software moderna para Inteligencia Artificial, la transformación de datos (que incluye el escalado, la imputación de valores faltantes y la codificación de variables categóricas) debe ocurrir imperativamente dentro del Pipeline de inferencia del modelo.

Desde una perspectiva de ingeniería de software, tratar las transformaciones como procesos externos al modelo como scripts SQL previos o limpiezas manuales en Excel es un antipatrón de diseño. Si las transformaciones se realizan fuera del pipeline, se crea una dependencia frágil donde el sistema de producción debe replicar exactamente la lógica matemática utilizada durante el entrenamiento. Cualquier discrepancia mínima (por ejemplo, una media distinta en el escalado) derivará en el fenómeno conocido como *Training-Serving Skew*, donde el modelo se comporta de forma errática a pesar de tener métricas excelentes en el laboratorio. Al encapsular estas operaciones en un objeto como Pipeline de Scikit-Learn, el modelo se convierte en una unidad atómica que recibe datos crudos y entrega predicciones, garantizando la coherencia estadística total.

Versionamiento de Modelos y Transformadores: El Enfoque MLOps

El versionamiento en Machine Learning es significativamente más complejo que el versionamiento de código tradicional. No basta con usar Git para rastrear cambios en los scripts; es necesario versionar el artefacto binario que contiene tanto el modelo como sus transformadores asociados.

En entornos profesionales, esto se logra mediante herramientas de Model Registry (como MLflow o DVC). El versionamiento debe vincular tres pilares:

1. **El Código:** La lógica exacta que generó el modelo.
2. **Los Datos:** El snapshot específico del dataset utilizado para el entrenamiento.
3. **Los Parámetros:** Los coeficientes aprendidos y los valores de los transformadores (ej. los parámetros del StandardScaler).

Versionar el transformador junto al modelo es crítico porque el modelo "espera" datos en una escala específica. Si actualizamos el modelo pero usamos una versión antigua del transformador, la entrada de datos estará sesgada, invalidando la salida.

Riesgos Críticos del Data Leakage (Fuga de Datos)

El *Data Leakage* es uno de los errores más costosos en la ciencia de datos, ya que genera una ilusión de éxito que se desmorona al enfrentar datos reales. Los riesgos se dividen en dos categorías principales:

- **Falso Optimismo y Riesgo Operativo:** El leakage infla artificialmente métricas como el *Accuracy* o el *F1-Score*. Si un ingeniero de software despliega un modelo de calificación registral que parece tener un 99% de precisión debido a que "filtró" información del futuro durante el entrenamiento, la institución tomará decisiones basadas en evidencia falsa. En producción, el modelo fallará catastróficamente al no contar con esa información privilegiada.
- **Vulnerabilidad de la Seguridad Jurídica:** En instituciones como el Registro de la Propiedad, un modelo con leakage puede aprender patrones que no tienen sustento legal, sino estadístico accidental. Esto compromete la fe pública, ya que la automatización no estaría basada en la lógica jurídica, sino en una "trampa" matemática involuntaria.

El Rol de la Gobernanza del Dato en el Proceso Analítico

La gobernanza del dato no es un proceso administrativo, sino un componente de calidad y control que atraviesa todo el pipeline. Su rol es fundamental en cuatro ejes:

1. **Integridad del Linaje:** Permite rastrear el origen de cada dato y asegurar que las variables utilizadas sean lícitas y éticas.
2. **Prevención de Sesgos:** Establece reglas de negocio que prohíben el uso de variables que puedan introducir discriminación o que se identifiquen como fuentes potenciales de *leakage*.
3. **Auditabilidad:** En caso de un error registral automatizado, la gobernanza proporciona el marco para auditar qué versión del modelo y qué datos influyeron en la decisión, asegurando la transparencia institucional.
4. **Estandarización:** Define cómo deben ser las transformaciones para que todos los equipos de la organización hablen el mismo "idioma" técnico, evitando que cada modelo tenga su propia interpretación de la limpieza de datos.

Conclusiones:

- 1) El flujo implementado en Orange permitió desarrollar un proceso completo de minería de datos que incluye:
 - Exploración inicial
 - Selección de variables
 - Muestreo
 - Preprocesamiento
 - Entrenamiento de múltiples modelos
 - Evaluación comparativa
 - Análisis detallado de desempeño
- 2) Se observó que la normalización impacta principalmente en modelos sensibles al escalamiento como SVM y Redes Neuronales, mejorando su desempeño. En contraste, Random Forest mostró estabilidad tanto con como sin normalización, debido a que los modelos basados en árboles no dependen de distancias matemáticas. Esto confirma que el escalamiento es fundamental en modelos lineales y basados en margen.
- 3) Los modelos basados en distancia o en optimización matemática, como SVM, Redes Neuronales y Regresión Logística, son sensibles al escalamiento debido a que dependen de magnitudes numéricas para calcular fronteras de decisión o ajustar pesos. En contraste, modelos basados en árboles como Random Forest no se ven afectados por la escala de las variables, ya que realizan divisiones mediante reglas independientes por variable.
- 4) La matriz de confusión del modelo Random Forest muestra una alta concentración de aciertos en la diagonal principal, confirmando su alto desempeño general. Las principales confusiones se presentan entre clases estructuralmente similares como Automóvil, Jeep y Motocicleta, lo que sugiere que algunas características pueden no ser completamente discriminativas. No obstante, el modelo mantiene una clasificación sólida en la mayoría de categorías.